

Koggi Data Warehouse — Generalidades

Documento ejecutivo de arquitectura de datos y BI. Complementa el manual detallado en **docs/koggi/** del repositorio. Generado el 14 de agosto de 2026 a partir de `compiled_graph.json` (Dataform), el diccionario de columnas de BigQuery y el directorio de tableros Looker Studio. **Auditado línea por línea contra el repo real** (zip del 6-ago-2026): coincidencia exacta en archivos, dependencias y declaraciones.

1. Qué es

Warehouse de BigQuery (proyecto `davinci-onegroup-prod`) que centraliza los leads, el motor de calificación crediticia (Profiling/MPK) y los seguimientos comerciales de Koggi. Dataform transforma los datos crudos (Firestore + sistema central) en tablas de negocio que Looker Studio consume directamente vía el conector nativo de BigQuery, sin capa intermedia.

2. Cifras clave

Tablas construidas por Dataform (con SQL en el repo)	27
Fuentes externas declaradas (Firestore / sistema central)	29
Tablas activas	21
Tablas deshabilitadas (SQL vigente, no se ejecutan)	6
Datasets en BigQuery	BI, BI_Staging, central_col_stream, firestore_calculator, firestore_collections
Tableros Looker Studio con tabla fuente mapeada	13
Tableros Looker Studio en el directorio general (todas las áreas)	44

3. Arquitectura en capas (medallion)

Bronze (crudo de Firestore) → Silver (`stg_*`, limpieza y estandarización) → Gold (tablas de negocio y OBTs para Looker: `fact_leads_followup`, `fact_leads_atribucion`, `tbl_contador_unificado`). Nota: solo 5 de las 27 tablas están organizadas físicamente en carpetas `bronze/` o `gold/` — el resto vive suelto en `definitions/` (detalle en la hoja de ruta AI-ready del manual completo).

4. Procesos fuera de Dataform

La dimensión de género (`dim_genero_nombres` / `dim_persona_genero`) se calcula con un notebook Python aparte (diccionario iterativo con revisión humana), no vía Dataform. No tiene assertions automáticas — ver hallazgos.

5. Hallazgos que requieren decisión del equipo

- Colisión de nombres entre la dimensión de género del notebook y la declarada en Dataform (3 nombres distintos para conceptos relacionados) — causa raíz confirmada: copy-paste en sources.js.
- 3 fuentes declaradas con descripción placeholder copiada de otra tabla (confirmado contra el código fuente real).
- 6 tablas con SQL vigente pero deshabilitadas — riesgo de que un tablero lea datos congelados sin saberlo.
- 2 tableros del directorio Koggi marcados "Pendiente de Migración", sin tabla BigQuery aún.
- Solo 9 de 26 tablas evaluables tienen assertions de Dataform — cobertura de tests baja, confirmada contra el repo real.

6. Siguiente paso propuesto

Cerrar los hallazgos anteriores, luego generar un manifiesto único versionado en CI y exponerlo vía servidor MCP de solo lectura, para que un agente de IA pueda responder "¿de dónde sale esta columna del tablero X?" citando la fuente real. Detalle completo en docs/koggi/hoja-de-ruta-ai-ready.md.

Para el detalle tabla por tabla, columna por columna, y el SQL de cada transformación, ver el manual completo en docs/koggi/(arquitectura-y-linaje.md, diccionario-datos.md, mapeo-tableros-looker.md, hallazgos-y-pendientes.md).